

# Bird Flu

# JcB 25/10/2015

Ce travail est inspiré de l'article hrbrmstr, lui même inspiré par un article du Wall Street Journal concernant la circulation de **virus aviaire pathogènes** dans les élevages US et illustré par un graphique accrocheur (Quite the eye-catching chart)



Le graphique est spectaculaire mais difficile à appréhender. L'objectif de l'auteur est de le transformer en barre graphe, moins tape à l'oeil mais plus informatif.



Reprendre ce travail m'a permis de:

- apprendre à extraire un tableau de données à partir d'une page HTML
- découvrir la librairy **viridis** (palette de couleur)
- de tansformer des formats de dates en modifiant la LOCALE de mon ordinateur
- de manipuler la librairie dplyr

## Library nécessaires

```
library(xml2)
library(rvest)
library(dplyr)

##
## Attaching package: 'dplyr'
##
```

```
## The following objects are masked from 'package:stats':
##
## filter, lag
##
## The following objects are masked from 'package:base':
##
## intersect, setdiff, setequal, union

library(stringr)
library(ggplot2)
library(scales)
library(viridis)
library(ggthemes)
```

### Récupérer les données source

write.csv(dat, file = "dat.csv")

Les données de base (raw data) sont issues de l'USDA (United States Department of Agriculture) à la page Update on Avian Influenza Findings - Poultry Findings Confirmed by USDA's National Veterinary Services Laboratories entre le 19/12/2014 (date de la première épidémie) et le 17/6/15.

```
# page internet où se trouve le tableau de données
pg <- read_html("https://www.aphis.usda.gov/wps/portal/aphis/ourfocus/animalhealth/sa_animal_disease_in
# pg est une liste de 2 éléments
names(pg)
# lecture de la table principale
dat <- html_table(html_nodes(pg, "table"))[[1]]
# sauvegarde</pre>
```

# dat est le dataframe correspondant au tableau 1 names(dat)

Les données brutes sont sauvegardées dans dat.csv pour économiser du temps

```
dat <- read.csv("dat.csv")
head(dat)</pre>
```

```
Х
##
           State
                                Flyway Flock.type
                                                           Species
## 1 1
            Iowa
                    Wright Mississippi Commercial Layer Chickens
            Iowa
                     Sioux Mississippi
                                          Backyard Mixed Game Fowl
## 3 3 Minnesota Kandiyohi Mississippi Commercial
                                                           Turkeys
## 4 4 Minnesota
                     Brown Mississippi Commercial
                                                           Turkeys
## 5 5
            Iowa
                       Sac Mississippi Commercial
                                                           Turkeys
## 6 6 Minnesota Renville Mississippi Commercial Pullet Chickens
##
     Avian.influenza.subtype. Confirmation.date Flock.size
## 1
                   EA/AM-H5N2
                                    Jun 17, 2015 1,000,000
## 2
                   EA/AM-H5N2
                                    Jun 9, 2015
                                                      2,500
## 3
                                    Jun 5, 2015
                                                     44,000
                   EA/AM-H5N2
## 4
                                    Jun 5, 2015
                   EA/AM-H5N2
                                                     39,000
```

```
## 5 EA/AM-H5N2 Jun 4, 2015 42,200
## 6 EA/AM-H5N2 Jun 4, 2015 415,000
```

Les colonnes retenues sont:


- confirmation date: date de début de l'épidémie
- flock size : taille de l'élevage

#### Préparation des données

La colonne date est au format US avec un nom de mois abrégé. Les mois abrégés US ne sont pas reconnus par le Locale français. Il faut donc temporairement mettre locale au format US. Pour la colonne flock size, il faut supprimer le séparateur de milliers. Par ailleurs ertains chiffres sont remplacés par pending.

```
# sauvegarde des constantes locales
local time <- Sys.getlocale(category = "LC TIME")</pre>
local_time
## [1] "fr_FR.UTF-8"
# mise en place du système US
Sys.setlocale(category = "LC_TIME", locale = 'en_GB.UTF-8')
## [1] "en_GB.UTF-8"
Sys.getlocale(category = "LC_TIME")
## [1] "en_GB.UTF-8"
\# dat$"Confirmation date" <- as.Date(dat$"Confirmation date", "%b %d, %Y")
# transformation des données en une passe
dat %>%
  mutate(`Confirmation.date` = as.Date(`Confirmation.date`, "%b %d, %Y"),
   week = format(`Confirmation.date`, "%Y-%U"),
   week_start = as.Date(sprintf("%s-1", week), "%Y-%U-%u")
    `Flock.size` = as.numeric(str_replace_all(`Flock.size`, ",", ""))) %>%
  select(week, week_start, `Flock.size`) %>%
  filter(!is.na(`Flock.size`)) %>%
  group_by(week_start) %>%
  summarize(outbreaks=n(),
   flock_total=sum(`Flock.size`)) -> dat
## Warning in eval(substitute(expr), envir, enclos): NAs introduits lors de la
## conversion automatique
```

```
## Source: local data frame [23 x 3]
##
##
      week start outbreaks flock total
##
                     (int)
                                  (dbl)
          (date)
## 1 2014-12-15
                         1
                                    130
## 2 2015-01-05
                         2
                                    730
## 3 2015-01-12
                         2
                                    140
## 4 2015-01-19
                         1
                                 134400
## 5
     2015-01-26
                         1
                                   5830
## 6 2015-02-02
                         1
                                     40
## 7 2015-02-09
                         1
                                 112900
## 8 2015-02-16
                                     70
                         1
## 9 2015-03-02
                         1
                                  44000
## 10 2015-03-09
                         4
                                  93130
## ..
            . . .
Suite
first <- dat[2,]</pre>
last <- tail(dat, 1)</pre>
first
## Source: local data frame [1 x 3]
##
##
     week_start outbreaks flock_total
                    (int)
                                 (dbl)
##
         (date)
## 1 2015-01-05
                                   730
                        2
last
## Source: local data frame [1 x 3]
##
##
     week_start outbreaks flock_total
##
         (date)
                    (int)
                                (dbl)
## 1 2015-06-15
                                 1e+06
gg <- ggplot(dat, aes(x=week_start, y=outbreaks))</pre>
gg <- gg + geom_vline(xintercept=as.numeric(first$week_start), linetype="dashed", size=0.2, color="#7f7"
gg <- gg + geom_text(data=first, aes(x=week_start, y=25), label="First detection in 2015", hjust=0, si
gg <- gg + geom_vline(xintercept=as.numeric(last$week_start), linetype="dashed", size=0.2, color="#7f7f
gg <- gg + geom_text(data=last, aes(x=week_start, y=25), label="Last detection", hjust=1, size=3, color
gg <- gg + geom_segment(aes(x=week_start, xend=week_start, y=0, yend=outbreaks, color=flock_total), siz
gg <- gg + geom_point(aes(size=flock_total, fill=flock_total), shape=21)
gg <- gg + scale_size_continuous(name="Flock Impact", label=comma, guide="legend")
gg <- gg + scale_color_viridis(name="Flock Impact", label=comma, guide="legend")</pre>
gg <- gg + scale_fill_viridis(name="Flock Impact", label=comma, guide="legend")
gg <- gg + scale_x_date(label=date_format("%b"))</pre>
gg <- gg + guides(color=guide_legend(), fill=guide_legend(), size=guide_legend())</pre>
gg <- gg + labs(x=NULL, y="# Outbreaks", title="Avian Flu Impact by Week (2015)")
gg <- gg + theme_tufte(base_family="Helvetica")</pre>
gg <- gg + theme(legend.key=element rect(color=rgb(0,0,0,0)))
gg
```




If we really want to see the discrete events, we can do that with our less-ZOMGOSH color scheme, too:

## Warning in eval(substitute(expr), envir, enclos): NAs introduits lors de la
## conversion automatique

#### head(dat)

```
##
       X
              State
                        County Flyway Flock.type
## 1 219
                       Douglas Pacific
                                       Backyard Mixed poultry
             Oregon
## 2 218 Washington
                        Benton Pacific
                                         Backyard Mixed poultry
## 3 217 Washington
                                         Backyard Mixed Poultry
                        Benton Pacific
## 4 215 Washington
                       Clallam Pacific
                                         Backyard Mixed Poultry
## 5 216
              Idaho
                        Canyon Pacific
                                         Backyard Mixed poultry
## 6 214 California Stanislaus Pacific Commercial
                                                         Turkeys
     Avian.influenza.subtype.
                                    date Flock.size
## 1
                     EA -H5N8 2014-12-19
                   EA/AM-H5N2 2015-01-03
                                                 140
## 2
```

```
## 3
                   EA/AM-H5N2 2015-01-09
                                                  590
## 4
                   EA/AM-H5N2 2015-01-16
                                                  110
## 5
                   EA/AM-H5N2 2015-01-16
                                                   30
                       EA-H5N8 2015-01-23
## 6
                                               134400
first <- dat[2,]</pre>
last <- tail(dat, 1)</pre>
gg <- ggplot(dat, aes(x=date, y=`Flock.size`))</pre>
gg <- gg + geom_vline(xintercept=as.numeric(first$date), linetype="dashed", size=0.2, color="#7f7f7f")
gg <- gg + geom_text(data=first, aes(x=date, y=3000000), label=" First detection in 2015", hjust=0, siz
gg <- gg + geom_vline(xintercept=as.numeric(last$date), linetype="dashed", size=0.2, color="#7f7f7f")
gg <- gg + geom_text(data=last, aes(x=date, y=3000000), label="Last detection ", hjust=1, size=3, color
gg <- gg + geom_segment(aes(x=date, xend=date, y=0, yend=`Flock.size`, color=`Flock.size`), size=0.5, a
gg <- gg + scale_size_continuous(name="Flock Impact", label=comma, guide="legend")
gg <- gg + scale_color_viridis(name="Flock Impact", label=comma, guide="legend")
gg <- gg + scale_fill_viridis(name="Flock Impact", label=comma, guide="legend")</pre>
gg <- gg + scale_x_date(label=date_format("%b"))</pre>
gg <- gg + scale_y_continuous(label=comma)</pre>
gg <- gg + guides(color=guide_legend(), fill=guide_legend(), size=guide_legend())</pre>
gg <- gg + labs(x=NULL, y="Flock.size", title="Avian Flu Impact (2015)")
gg <- gg + theme_tufte(base_family="Helvetica")</pre>
gg <- gg + theme(legend.key=element_rect(color=rgb(0,0,0,0)))</pre>
gg
```



Restauration

```
# restauration du système français
Sys.setlocale(category = "LC_TIME", locale = local_time)
```

## [1] "fr\_FR.UTF-8"